

Patrones de consumo en una plataforma de streaming

Informe final — Proyecto Integrador, Minería de Datos 1

Contexto y objetivo

Se analizó un dataset de usuarios de una plataforma de streaming para responder: ¿cómo se relaciona el tiempo mensual de visualización con el plan de suscripción y el país de los usuarios? El objetivo es identificar patrones de consumo que orienten decisiones de producto o negocio.

Dataset y calidad inicial

El dataset original contiene 8160 registros con 8 variables (edad, plan, tiempo de visualización mensual, país, género favorito, fecha de último login, tickets de soporte). La inspección inicial detectó: 160 user_id duplicados y 126 filas 100% duplicadas; variantes de texto inconsistentes en subscription_plan (15), country (26) y favorite_genre (29); valores imposibles en age (-5 a 150) y en monthly_watch_time_mins (negativos y un valor centinela en 99999); y last_login_date con al menos 3 formatos distintos, nulos y strings inválidos.

Decisiones de limpieza y preparación

Se eliminaron duplicados (8160 → 8000 filas). Las variables categóricas se normalizaron (texto y mapeo de variantes a categoría canónica). age se acotó a [13, 100] e imputó por mediana según plan. monthly_watch_time_mins —variable central del análisis— se limpió con especial cuidado: los valores negativos y el centinela 99999 se pasaron a nulo, y los nulos resultantes se imputaron con la mediana por combinación (plan, país), para no introducir un sesgo que aplanara el patrón buscado. customer_support_tickets se acotó a [0, 30] (capping). last_login_date se unificó a formato datetime. Cada paso quedó registrado con filas, nulos y % de retención en logs/pipeline_log.csv.

Hallazgos del análisis exploratorio

El tiempo de visualización tiene distribución con cola hacia la derecha. Al cruzarlo con plan de suscripción aparece el hallazgo principal: la mediana casi se duplica entre planes (Básico ≈553 min/mes, Estándar ≈839, Premium ≈1122). El país, en cambio, aporta una diferencia mucho menor (≈758 a ≈795 min/mes de mediana entre países, ~5%). El cruce país × plan muestra que el salto de consumo al subir de plan (540–610 min) se repite de forma consistente en los 7 países: no hay una interacción fuerte entre ambas variables.

PCA

Se aplicó PCA sobre age, monthly_watch_time_mins y customer_support_tickets, previamente escaladas con StandardScaler (las tres variables están en escalas muy distintas). Las tres componentes explican una proporción pareja de la varianza (33.6% / 33.3% / 33.2%), ya que las variables tienen correlaciones cercanas a cero entre sí. La proyección en las dos primeras componentes no separa usuarios por plan, porque age y customer_support_tickets no varían con el plan: el fuerte efecto del plan encontrado en el EDA es específico del tiempo de visualización, no de un perfil numérico general del usuario.

Conclusiones y limitaciones

El patrón de consumo está principalmente explicado por el plan de suscripción; el país actúa como factor secundario y consistente, sin interacción fuerte con el plan. Limitación: el dataset no incluye contenido consumido, dispositivo o franja horaria, que podrían explicar la variabilidad de consumo dentro de un mismo plan; además, 262 valores de monthly_watch_time_mins fueron imputados durante la limpieza. Como mejora futura, se propone incorporar esas variables adicionales y analizar la evolución temporal del consumo.

Enlaces

Repositorio GitHub: *(completar con el enlace público del repositorio)*

Aplicación Streamlit: *(completar con el enlace público de Streamlit Cloud)*